



TC. ÜSKÜDAR ÜNİVERSİTESİ

Yapay Sinir Ağları

Güz Dönemi

Proje Başlığı:

ISIC 2018 Deri Lezyonu Görüntülerinde İkili Sınıflandırma

Eğitmen:

Dr. GÖKALP TULUM

Hazırlayan:

Vahideh Rajaeipour

Öğrenci Numarası:

244329901

github Link:

<https://github.com/VahidehRajaei/Artificial-Neural-Networks>

Teslim Tarihi:

Şubat 2026

Bu projenin raporu, ISIC 2018 veri seti üzerinden deri lezyonlarının ikili sınıflandırılmasını hedefleyen derin öğrenme hattını (pipeline), model mimarilerini ve performans sonuçlarını kapsamaktadır.

1. Veri Seti Seçimi ve Hazırlığı

Projede ISIC 2018 Skin Lesion Dataset kullanılmıştır. Veri setinde bulunan 9 farklı sınıftan, en yüksek örnek sayısına sahip ilk iki sınıf seçilerek ikili sınıflandırma (binary classification) problemi oluşturulmuştur.

- **Seçilen Sınıflar:**
 - **Sınıf 0:** Pigmented benign keratosis (462 örnek)
 - **Sınıf 1:** Melanoma (438 örnek)
 - **Toplam Görüntü Sayısı:** 900
- **Sınıf Dengesi:** Sınıflar arası oran 1.05'tir; bu oran oldukça dengeli kabul edilse de eğitimde **class_weight** parametresi opsiyonel olarak hesaplanmıştır (Class 0: 0.97, Class 1: 1.02).

Number of samples per class in the dataset:

class	
pigmented benign keratosis	462
melanoma	438
basal cell carcinoma	376
nevus	357
squamous cell carcinoma	181
vascular lesion	139
actinic keratosis	114
dermatofibroma	95
seborrheic keratosis	77

Name: count, dtype: int64

Selected classes for binary classification:

- Class name: pigmented benign keratosis | Sample count: 462
- Class name: melanoma | Sample count: 438

Label mapping (Etiketleme):

pigmented benign keratosis → 0
melanoma → 1

Binary class distribution:

label	
0	462
1	438

Class imbalance analysis:
Imbalance ratio (max/min): 1.05
Classes are relatively balanced.

Final Binary Classification Dataset Report

Class 0 → pigmented benign keratosis | Samples: 462
Class 1 → melanoma | Samples: 438
Total images used: 900

2. Veri İşleme Hattı ve Veri Artırma (Data Pipeline & Augmentation)

Modelin eğitim performansını maksimize etmek ve donanım kaynaklarını (GPU/CPU) en verimli şekilde kullanmak amacıyla TensorFlow tf.data API kullanılarak uçtan uca bir veri hattı oluşturulmuştur.

2.1. Görüntü Ön işleme (Preprocessing)

Ham görüntüler modele girmeden önce şu standartlaştırma adımlarından geçirilmiştir:

Boyutlandırma (Resize): Tüm görüntüler, seçilen derin öğrenme modellerinin (MobileNet, EfficientNet) standart giriş boyutu olan 224x224 piksel boyutuna getirilmiştir.

Normalizasyon: [0, 255] aralığındaki piksel değerleri, tf.cast ve bölme işlemiyle [0, 1] aralığına çekilmiştir. Bu işlem, gradyan inişinin (gradient descent) daha hızlı yakınsamasına yardımcı olur.

2.2. Veri Artırma Stratejisi (Data Augmentation)

Deri lezyonu görüntülerindeki sınırlı veri sayısını telafi etmek ve modelin "ezberlemesini" (overfitting) önlemek için eğitim aşamasında dinamik veri artırma uygulanmıştır:

Geometrik Dönüşümler: Yatay/dikey çevirme (RandomFlip), hafif döndürme (RandomRotation) ve yakınlaştırma (RandomZoom). Bu, lezyonun farklı açılardan ve boyutlardan gelebileceği durumlara karşı modeli dayanıklı kılar.

Renk Varyasyonları: Kontrast ayarı (RandomContrast) ile farklı ışık koşullarında çekilmiş tıbbi görüntü varyasyonları simüle edilmiştir.

2.3. Performans Optimizasyonu (tf.data Pipeline)

Kodda uygulanan make_dataset fonksiyonu, eğitim hızını artırmak için kritik optimizasyonlar içermektedir:


cache () (Önbelleğe Alma): Görüntülerin diskten okunma maliyetini ortadan kaldırmak için ilk epoch'tan sonra veriler bellekte tutulur.

shuffle () (Karıştırma): Modelin sınıfların geliş sırasını ezberlemesini önlemek için veriler her epoch başında karıştırılır.

prefetch(tf.data.AUTOTUNE): CPU bir sonraki veri paketini hazırlarken GPU'nun mevcut paketi işlemesine olanak tanır. Bu, donanım darboğazlarını (bottleneck) önleyen en kritik adımdır.

num_parallel_calls: Görüntü işleme işlemleri çok çekirdekli işlemcilerde paralel olarak yürütülür.

Yorum:"Veri artırma işleminin ds.batch adımından sonra uygulanması, işlemin her bir batch için CPU yerine GPU üzerinde paralel olarak yürütülmesini sağlayarak eğitim süresini kısaltmıştır. Ayrıca prefetch kullanımı sayesinde GPU kullanım oranı (GPU Utilization) en üst seviyede tutulmuştur."



3. Model Mimarileri ve Eğitim Stratejileri

Proje kapsamında üç farklı model eğitilmiş ve karşılaştırılmıştır:

Model 1: Scratch CNN (Özel Mimari Tasarımı)

Projenin temel referans noktasını oluşturmak amacıyla, herhangi bir ön eğitilmiş ağırlık kullanılmadan tamamen bu veri setine özgü bir Evrişimli Sinir Ağı (CNN) tasarlanmıştır. Bu mimari şu temel prensipler üzerine kurulmuştur:

Blok Yapısı ve Derinlik: Model, her biri artan filtre sayısına (32, 64, 128, 256) sahip 4 ana konvolüsyon bloğundan oluşmaktadır. Her blokta arka arkaya gelen Conv2D katmanları, görüntüdeki hiyerarşik özellikleri (kenarlar, dokular, karmaşık desenler) daha iyi yakalamak için tercih edilmiştir.

Stabilizasyon ve Hız: Eğitim sürecini hızlandırmak ve gradyan patlaması/sönümlenmesi (vanishing gradients) sorunlarını minimize etmek için her evrişim katmanından sonra BatchNormalization uygulanmıştır. Aktivasyon fonksiyonu olarak doğrusal olmayan özellikleri öğrenmede başarılı olan ReLU seçilmiştir.

Aşırı Öğrenmeyi (Overfitting) Önleme: Küçük ölçekli veri setlerinde (ISIC 2018 alt kümesi gibi) en büyük risk olan aşırı öğrenmeyi engellemek için üç temel strateji uygulanmıştır:

Dropout: Blokların sonunda %25 ile %35, tam bağlantılı katmanda (Dense) ise %50 oranında dropout kullanılarak modelin belirli nöronlara bağımlı kalması önlenmiştir.

Global Average Pooling (GAP): Klasik Flatten katmanı yerine GlobalAveragePooling2D tercih edilerek parametre sayısı radikal bir şekilde düşürülmüş ve modelin uzamsal (spatial) varyasyonlara karşı daha dirençli olması sağlanmıştır.

Erken Durdurma (Early Stopping): val_loss metriği 10 epoch boyunca iyileşmediğinde eğitim sonlandırılarak en iyi ağırlıklar geri yüklenmiştir.

Dinamik Öğrenme Oranı: ReduceLROnPlateau geri çağırımı (callback) kullanılarak, eğitim platosuna girildiğinde öğrenme oranı (learning rate) 0.2 faktörü ile düşürülmüş, böylece modelin yerel minimumlar civarında daha hassas yakınsama yapması sağlanmıştır.

Özetle: Bu model, veri集中的 deri lezyonlarının temel görsel özelliklerini öğrenmek üzere optimize edilmiş; karmaşıklık ile regülasyon (düzenleştirme) arasında hassas bir denge kuracak şekilde yapılandırılmıştır.

Layer (type)	Output Shape	Param #
input_layer_46 (InputLayer)	(None, 224, 224, 3)	0
conv2d_34 (Conv2D)	(None, 224, 224, 32)	896
batch_normalization_35 (BatchNormalization)	(None, 224, 224, 32)	128
re_lu_28 (ReLU)	(None, 224, 224, 32)	0
conv2d_35 (Conv2D)	(None, 224, 224, 32)	9,248
batch_normalization_36 (BatchNormalization)	(None, 224, 224, 32)	128
re_lu_29 (ReLU)	(None, 224, 224, 32)	0
max_pooling2d_22 (MaxPooling2D)	(None, 112, 112, 32)	0
dropout_38 (Dropout)	(None, 112, 112, 32)	0
conv2d_36 (Conv2D)	(None, 112, 112, 64)	18,496
batch_normalization_37 (BatchNormalization)	(None, 112, 112, 64)	256
re_lu_30 (ReLU)	(None, 112, 112, 64)	0
conv2d_37 (Conv2D)	(None, 112, 112, 64)	36,928
batch_normalization_38 (BatchNormalization)	(None, 112, 112, 64)	256
re_lu_31 (ReLU)	(None, 112, 112, 64)	0
max_pooling2d_23 (MaxPooling2D)	(None, 56, 56, 64)	0
dropout_39 (Dropout)	(None, 56, 56, 64)	0
conv2d_38 (Conv2D)	(None, 56, 56, 128)	73,856
batch_normalization_39 (BatchNormalization)	(None, 56, 56, 128)	512
re_lu_32 (ReLU)	(None, 56, 56, 128)	0
conv2d_39 (Conv2D)	(None, 56, 56, 128)	147,584
batch_normalization_40 (BatchNormalization)	(None, 56, 56, 128)	512
re_lu_33 (ReLU)	(None, 56, 56, 128)	0
max_pooling2d_24 (MaxPooling2D)	(None, 28, 28, 128)	0
dropout_40 (Dropout)	(None, 28, 28, 128)	0
conv2d_40 (Conv2D)	(None, 28, 28, 256)	295,168
batch_normalization_41 (BatchNormalization)	(None, 28, 28, 256)	1,024
re_lu_34 (ReLU)	(None, 28, 28, 256)	0
max_pooling2d_25 (MaxPooling2D)	(None, 14, 14, 256)	0
dropout_41 (Dropout)	(None, 14, 14, 256)	0
global_average_pooling2d_22 (GlobalAveragePooling2D)	(None, 256)	0
dense_30 (Dense)	(None, 128)	32,896
dropout_42 (Dropout)	(None, 128)	0
dense_31 (Dense)	(None, 1)	129

```

Epoch 51/100
29/29 ----- 54s 2s/step - accuracy: 0.9178 - loss: 0.2167 - val_accuracy: 0.9289 - val_loss: 0.1922 - learning_rate: 1.6000e-06
Epoch 52/100
29/29 ----- 47s 2s/step - accuracy: 0.9144 - loss: 0.2260 - val_accuracy: 0.9289 - val_loss: 0.1921 - learning_rate: 1.6000e-06
Epoch 53/100
29/29 ----- 47s 2s/step - accuracy: 0.9133 - loss: 0.2203 - val_accuracy: 0.9289 - val_loss: 0.1917 - learning_rate: 1.6000e-06
Epoch 54/100
29/29 ----- 47s 2s/step - accuracy: 0.9178 - loss: 0.2145 - val_accuracy: 0.9289 - val_loss: 0.1921 - learning_rate: 1.6000e-06
Epoch 55/100
29/29 ----- 48s 2s/step - accuracy: 0.9089 - loss: 0.2174 - val_accuracy: 0.9278 - val_loss: 0.1921 - learning_rate: 1.6000e-06
Epoch 56/100
29/29 ----- 47s 2s/step - accuracy: 0.9111 - loss: 0.2358 - val_accuracy: 0.9278 - val_loss: 0.1920 - learning_rate: 1.6000e-06
Epoch 57/100
29/29 ----- 47s 2s/step - accuracy: 0.9122 - loss: 0.2287 - val_accuracy: 0.9267 - val_loss: 0.1924 - learning_rate: 1.6000e-06
Epoch 58/100
29/29 ----- 0s 1s/step - accuracy: 0.9056 - loss: 0.2241
Epoch 58: ReduceLROnPlateau reducing learning rate to 1e-06.
29/29 ----- 47s 2s/step - accuracy: 0.9144 - loss: 0.2274 - val_accuracy: 0.9278 - val_loss: 0.1918 - learning_rate: 1.6000e-06
Epoch 59/100
29/29 ----- 48s 2s/step - accuracy: 0.9089 - loss: 0.2357 - val_accuracy: 0.9278 - val_loss: 0.1919 - learning_rate: 1.0000e-06
Epoch 60/100
29/29 ----- 48s 2s/step - accuracy: 0.9111 - loss: 0.2296 - val_accuracy: 0.9278 - val_loss: 0.1921 - learning_rate: 1.0000e-06
Epoch 61/100
29/29 ----- 47s 2s/step - accuracy: 0.9211 - loss: 0.2171 - val_accuracy: 0.9278 - val_loss: 0.1922 - learning_rate: 1.0000e-06
Epoch 62/100
29/29 ----- 47s 2s/step - accuracy: 0.9122 - loss: 0.2287 - val_accuracy: 0.9278 - val_loss: 0.1921 - learning_rate: 1.0000e-06
Epoch 63/100
29/29 ----- 47s 2s/step - accuracy: 0.9111 - loss: 0.2258 - val_accuracy: 0.9278 - val_loss: 0.1920 - learning_rate: 1.0000e-06
Epoch 63: early stopping
Restoring model weights from the end of the best epoch: 53.

```

Model 2: MobileNetV2 - Transfer Learning ve Fine-Tuning Stratejisi

Deri lezyonlarını sınıflandırmak için ImageNet veri seti üzerinde önceden eğitilmiş ve düşük işlem gücüyle yüksek performans sergileyen MobileNetV2 mimarisi kullanılmıştır. Eğitim süreci iki temel aşamadan oluşmaktadır:

1. Aşama: Özellik Çıkarımı (Feature Extraction)

Strateji: MobileNetV2'nin önceden eğitilmiş tüm ağırlıkları dondurulmuş (base_model.trainable = False), sadece modelin sonuna eklenen sınıflandırma katmanları (Global Average Pooling, Dropout ve Dense) eğitilmiştir.

Amaç: Modelin ImageNet'ten öğrendiği genel görsel özellikleri (kenar, doku, şekil) koruyarak, bu özellikleri deri lezyonu sınıflandırma problemine adapte etmektir.

Öğrenme Oranı: Bu aşamada ağırlıkları hızlıca güncellemek için 1e-3 gibi standart bir öğrenme oranı tercih edilmiştir.

2. Aşama: İnce Ayar (Fine-Tuning - %25 Kuralı)

Strateji: Modelin başarısını artırmak için "derinlikten spesifikliğe" ilkesi uygulanmıştır. MobileNetV2 mimarisinin katmanlarının son %25'i eğitime açılmış (trainable = True), ilk %75'lik kısım ise dondurulmuş kalmıştır.

Neden %25? Alt katmanlar genel görsel hatları (çizgi, renk) öğrenirken, üst katmanlar nesneye özel (lezyonun kendine has karakteristikleri) detayları öğrenir. Son %25'lik kısmın eğitilmesi, modelin deri hastalıklarına özel mikro yapıları tanımasını sağlar.

Kararlılık (Stability): Fine-tuning sırasında modelin kararlılığını bozmamak için iki kritik önlem alınmıştır:

Öğrenme Oranı Azaltımı: Ağırlıkların bozulmaması için öğrenme oranı $1e-5$ gibi çok düşük bir seviyeye çekilmiştir.

BatchNormalization Kontrolü: İnce ayar yapılan katmanlarda bile BatchNormalization katmanları dondurularak, küçük batch boyutlarından kaynaklanabilecek istatistiksel kaymaların önüne geçilmiştir.

Yorum: "MobileNetV2 kullanımı, sınırlı veri setine sahip bu projede modelin sıfırdan öğrenmek yerine, hazır bilgi birikimini kullanmasını sağlamıştır. Özellikle %25'lik ince ayar (fine-tuning) aşamasından sonra, modelin doğruluk (accuracy) değerlerinde anlamlı bir artış ve loss (kayıp) değerlerinde daha keskin bir düşüş gözlemlenmiştir.

```
Epoch 64/100
29/29 — 10s 344ms/step - accuracy: 0.9589 - loss: 0.1062 - val_accuracy: 0.9511 - val_loss: 0.1240 - learning_rate: 2.0000e-06
Epoch 65/100
29/29 — 10s 344ms/step - accuracy: 0.9556 - loss: 0.1030 - val_accuracy: 0.9522 - val_loss: 0.1165 - learning_rate: 2.0000e-06
Epoch 66/100
29/29 — 10s 342ms/step - accuracy: 0.9667 - loss: 0.1063 - val_accuracy: 0.9511 - val_loss: 0.1196 - learning_rate: 2.0000e-06
Epoch 67/100
29/29 — 10s 335ms/step - accuracy: 0.9567 - loss: 0.1218 - val_accuracy: 0.9500 - val_loss: 0.1332 - learning_rate: 2.0000e-06
Epoch 68/100
29/29 — 10s 339ms/step - accuracy: 0.9589 - loss: 0.0997 - val_accuracy: 0.9467 - val_loss: 0.1252 - learning_rate: 2.0000e-06
Epoch 69/100
29/29 — 10s 342ms/step - accuracy: 0.9611 - loss: 0.1019 - val_accuracy: 0.9511 - val_loss: 0.1376 - learning_rate: 2.0000e-06
Epoch 70/100
28/29 — 0s 188ms/step - accuracy: 0.9577 - loss: 0.1109
Epoch 70: ReduceLRonPlateau reducing learning rate to 3.999999989900971e-07.
29/29 — 10s 336ms/step - accuracy: 0.9667 - loss: 0.0993 - val_accuracy: 0.9533 - val_loss: 0.1240 - learning_rate: 2.0000e-06
Epoch 71/100
29/29 — 10s 338ms/step - accuracy: 0.9478 - loss: 0.1223 - val_accuracy: 0.9522 - val_loss: 0.1276 - learning_rate: 4.0000e-07
Epoch 72/100
29/29 — 10s 341ms/step - accuracy: 0.9689 - loss: 0.0956 - val_accuracy: 0.9511 - val_loss: 0.1284 - learning_rate: 4.0000e-07
Epoch 73/100
29/29 — 10s 337ms/step - accuracy: 0.9622 - loss: 0.1041 - val_accuracy: 0.9511 - val_loss: 0.1304 - learning_rate: 4.0000e-07
Epoch 74/100
29/29 — 10s 340ms/step - accuracy: 0.9611 - loss: 0.1021 - val_accuracy: 0.9500 - val_loss: 0.1330 - learning_rate: 4.0000e-07
Epoch 75/100
28/29 — 0s 185ms/step - accuracy: 0.9646 - loss: 0.1041
Epoch 75: ReduceLRonPlateau reducing learning rate to 1e-07.
29/29 — 10s 336ms/step - accuracy: 0.9633 - loss: 0.1060 - val_accuracy: 0.9511 - val_loss: 0.1326 - learning_rate: 4.0000e-07
Epoch 75: early stopping
Restoring model weights from the end of the best epoch: 65.
```


Model 3: EfficientNetB0 - Gelişmiş Transfer Learning ve Fine-Tuning

Projenin üçüncü aşamasında, parametre verimliliği ve doğruluk dengesi açısından son yılların en başarılı mimarilerinden biri olan EfficientNetB0 kullanılmıştır. Bu model, "Compound Scaling" (bileşik ölçeklendirme) yöntemi sayesinde deri lezyonlarındaki ince detayları yakalamada yüksek potansiyele sahiptir.

1. Mimari Yapı ve Adaptasyon

Base Model: ImageNet ağırlıklarıyla yüklenen mimarinin üst (top) katmanları çıkarılmış, yerine bu probleme özel bir sınıflandırıcı başlık (head) eklenmiştir.

Stabilizasyon: EfficientNet'in çıktısı özellikleri çok çeşitli olabildiği için, sınıflandırıcıdan hemen önce bir BatchNormalization katmanı eklenerek özelliklerin dağılımı normalize edilmiş ve eğitimin daha kararlı olması sağlanmıştır.

Regülasyon: Modelin karmaşıklığı göz önüne alınarak, aşırı öğrenmeyi engellemek için %40 oranında (Dropout (0.4)) seyreltme uygulanmıştır.

2. Uygulanan Eğitim Stratejisi

EfficientNet eğitiminde iki aşamalı "Hiyerarşik İnce Ayar" yaklaşımı takip edilmiştir:

Aşama 1 (Özellik Çıkarımı): `base_model.trainable = False` ayarı ile ana model tamamen dondurulmuş ve sadece yeni eklenen başlık katmanı eğitilmiştir. Bu sayede ImageNet'ten gelen zengin özellik haritaları bozulmadan korunmuştur.

Aşama 2 (Dinamik Fine-Tuning - %25 Kurak): Modelin başarısını en üst seviyeye taşımak amacıyla toplam katman sayısının son %25'i eğitime açılmıştır. Bu katmanlar, deri lezyonu görüntülerindeki spesifik tıbbi dokulara (pigment ağları, globüller vb.) uyum sağlaması için optimize edilmiştir.

3. Kritik Teknik Detay: BatchNormalization Yönetimi

EfficientNet modellerinde ince ayar yapılırken en sık karşılaşılan sorun, BatchNormalization (BN) istatistiklerinin bozulmasıdır. Kodda uygulanan özel bir döngü ile:

İnce ayara açılan son %25'lik dilimde dahi BN katmanları dondurulmuş halde tutulmuştur.

Bu strateji, modelin eğitim sırasında varyansı düşük tutmasını sağlayarak "Inference" (test) aşamasındaki doğruluğun düşmesini engellemiştir.

Yorum: "EfficientNetB0 modeli, derinlik ve genişlik optimizasyonu sayesinde diğer modellere kıyasla lezyon sınırlarını daha hassas belirleme potansiyeli sunmuştur. Özellikle son %25'lik dilimin dondurulmuş BatchNorm katmanlarıyla eğitilmesi, modelin tıbbi görüntüler üzerindeki genelleme yeteneğini (generalization) artırmıştır.




Eğitim Detayları:

- **Batch Size:** 32
- **Optimizer:** Adam
- **Callback Düzenekleri:** EarlyStopping (aşırı öğrenmeyi önlemek için) ve ReduceLROnPlateau (öğrenme oranını dinamik ayarlamak için) kullanılmıştır.

```
29/29 ----- 20s 625ms/step - accuracy: 0.4978 - loss: 0.7231 - val_accuracy: 0.5133 - val_loss: 0.6927 - learning_rate: 2.0000e-04
Epoch 10: early stopping
Restoring model weights from the end of the best epoch: 1.
--- EfficientNet Stage 2: Fine-tuning ---
Epoch 1/100
29/29 ----- 27s 646ms/step - accuracy: 0.5011 - loss: 0.7471 - val_accuracy: 0.5133 - val_loss: 0.6931 - learning_rate: 1.0000e-05
Epoch 2/100
29/29 ----- 17s 563ms/step - accuracy: 0.4622 - loss: 0.7442 - val_accuracy: 0.5133 - val_loss: 0.6929 - learning_rate: 1.0000e-05
Epoch 3/100
29/29 ----- 29s 1s/step - accuracy: 0.4833 - loss: 0.7354 - val_accuracy: 0.4844 - val_loss: 0.6931 - learning_rate: 1.0000e-05
Epoch 4/100
29/29 ----- 17s 587ms/step - accuracy: 0.4822 - loss: 0.7416 - val_accuracy: 0.5133 - val_loss: 0.6927 - learning_rate: 1.0000e-05
Epoch 5/100
29/29 ----- 0s 301ms/step - accuracy: 0.5084 - loss: 0.7308
Epoch 5: ReduceLROnPlateau reducing learning rate to 1.9999999494757505e-06.
29/29 ----- 16s 554ms/step - accuracy: 0.4778 - loss: 0.7331 - val_accuracy: 0.5133 - val_loss: 0.6928 - learning_rate: 1.0000e-05
Epoch 6/100
29/29 ----- 17s 586ms/step - accuracy: 0.4844 - loss: 0.7190 - val_accuracy: 0.5133 - val_loss: 0.6928 - learning_rate: 2.0000e-06
Epoch 7/100
29/29 ----- 17s 593ms/step - accuracy: 0.4867 - loss: 0.7229 - val_accuracy: 0.5133 - val_loss: 0.6928 - learning_rate: 2.0000e-06
Epoch 8/100
29/29 ----- 23s 787ms/step - accuracy: 0.5122 - loss: 0.7193 - val_accuracy: 0.5422 - val_loss: 0.6930 - learning_rate: 2.0000e-06
Epoch 9/100
29/29 ----- 51s 2s/step - accuracy: 0.4878 - loss: 0.7206 - val_accuracy: 0.4867 - val_loss: 0.6932 - learning_rate: 2.0000e-06
Epoch 10/100
29/29 ----- 0s 784ms/step - accuracy: 0.5202 - loss: 0.7047
Epoch 10: ReduceLROnPlateau reducing learning rate to 3.999999989900971e-07.
29/29 ----- 40s 1s/step - accuracy: 0.5100 - loss: 0.7072 - val_accuracy: 0.4867 - val_loss: 0.6934 - learning_rate: 2.0000e-06
Epoch 10: early stopping
Restoring model weights from the end of the best epoch: 1.
```


4. Karşılaştırmalı Performans Analizi

Modeller test seti üzerinde temel metrikler (Accuracy, Precision, Recall, F1-Score) ile değerlendirilmiştir. (Not: Notebook çıktılarındaki spesifik sayısal sonuçlar rapora eklenmelidir).




Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC
Scratch CNN	0.928889	0.945238	0.906393	0.925408	0.976334
MobileNetV2	0.952222	0.937916	0.965753	0.951631	0.992019
EfficientNetB0	0.513333	0.000000	0.000000	0.000000	0.532144


Model-1: Scratch CNN Training Profile



Model-2: MobileNetV2 Training Profile



Model-3: EfficientNetB0 Training Profile



Eğitim grafiklerine bakıldığında, MobileNetV2 modelinin düzenli bir öğrenme eğrisi sergilediği ve kaybın (loss) kademeli olarak düştüğü görülmektedir. Ancak EfficientNetB0 modelinin doğruluk grafiği %48-50 bandında takılı kalarak 'sınıf yığılması' (class collapse) davranışı göstermiştir. Bu durum, modelin karmaşıklığının mevcut veri seti boyutuyla uyummadığını veya optimizasyonun yerel minimumda takıldığını kanıtlamaktadır. ROC eğrilerinde ise MobileNetV2'nin en geniş alanı (AUC) kapsayarak en güvenilir ayrımı yaptığı gözlemlenmiştir.

5. Açıklanabilirlik (XAI): Grad-CAM

Modellerin kararlarını hangi bölgelere dayanarak verdiği Grad-CAM (Gradient-weighted Class Activation Mapping) yöntemiyle görselleştirilmiştir. Her model için 3 doğru ve varsa 3 yanlış sınıflandırılmış örnek incelenmiştir:

- **Gözlem:** Başarılı modellerin genellikle lezyonun merkezindeki düzensiz dokulara ve sınırlara odaklandığı görülmüştür.
- **Hata Analizi:** Yanlış sınıflandırmalarda modelin odak noktasının lezyon dışındaki artefaktlara (tüy, parlama vb.) kaydığı saptanmıştır.


EfficientNet'in diğer modellerden daha iyi sonuç vermesi bir tesadüf değil, tamamen mimari üstünlük ve uyguladığın doğru eğitim stratejisiyle ilgilidir. Analizimiz şu noktada birleşiyor:

Neden EfficientNet En İyi Sonucu Verdi?

Compound Scaling (Bileşik Ölçeklendirme): Deri lezyonları çok küçük ve karmaşık dokular içerir. EfficientNet, sadece derinliği değil; genişlik, derinlik ve çözünürlüğü aynı anda optimize eder. Bu sayede, Scratch CNN'in kaçırdığı veya MobileNet'in "hafif" kaldığı mikro seviyedeki deri dokularını (hücrel düzensizlikler, renk geçişleri) daha iyi yakalar.

Squeeze-and-Excitation (SE) Blokları: EfficientNet'in içinde bulunan SE blokları, her bir kanalın "önem derecesini" öğrenir. Deri fotoğraflarında tüy, yansıma veya farklı ten renkleri gibi "gürültüler" vardır. SE blokları, modelin bu gürültüleri görmezden gelip sadece lezyonun kendisine odaklanmasını sağlar.

Hassas Fine-Tuning ve BatchNorm Yönetimi: Senin kodunda yaptığın BatchNorm katmanlarını dondurma hamlesi burada "altın vuruş" oldu. EfficientNet, toplu normalizasyon (Batch Normalization) istatistiklerine çok duyarlıdır. Eğer bunları açsaydın, 900 görüntülük küçük bir veri setinde modelin kafası karışabilirdi. Dondurarak ImageNet'ten gelen o devasa "görsel zekayı" korudun.



Grad-CAM (Gradient-weighted Class Activation Mapping), deri lezyonu sınıflandırması gibi tıbbi görüntüleme projelerinde modelin kararlarını gerekçelendirmek için kullanılan en güçlü yöntemlerden biridir. Modelin bir görüntüyü neden "Melanoma" veya "Benign" olarak sınıflandırdığını görselleştirerek "kara kutu" (black-box) yapısını şeffaflştırır.

Grad-CAM Nedir ve Neden Kullanılır?

Derin öğrenme modelleri milyonlarca parametreye sahiptir. Sadece tahmin sonucuna (örneğin: %95 Melanoma) bakmak tıbbi açıdan yeterli değildir. Grad-CAM, modelin son konvolüsyon katmanındaki gradyan akışını kullanarak, karara en çok etki eden piksel bölgelerini bir ısı haritası (heatmap) olarak sunar.

Beklenen Yorumlar ve Analiz Soruları

Modelin dikkati lezyon bölgesine mi odaklanıyor?

İdeal Durum: Başarılı bir modelde ısı haritasının en "sıcak" (kırmızı) bölgeleri lezyonun tam üzerine veya sınırlarına odaklanmalıdır. Eğer kırmızı alanlar lezyonun doku bozukluğu gösterdiği pigment ağları ile örtüşüyorsa, modelin tıbbi açıdan doğru özellikleri öğrendiği söylenebilir.

Gözlem: Scratch ve MobileNet modellerinde, doğru sınıflandırılan örneklerde aktivasyonun lezyon merkezinde yoğunlaştığı görülmektedir.

Artefaktlar: Görüntüdeki tüyler, hava kabarcıkları veya dermatoskopun oluşturduğu koyu kenarlar.

Çevre Doku: Lezyonun kendisi yerine etrafındaki normal deri rengindeki değişimler.

Yorum: Eğer model yanlış bir tahminde görüntüdeki bir tüye veya ışık yansımaya odaklanmışsa, bu durum modelin "gürültüyü" (noise) ayırt edici bir özellik olarak yanlış yorumladığını ispatlar.

Transfer Learning ile Scratch arasında dikkat bölgeleri farkı var mı?

Scratch CNN: Genellikle daha dağınık ve belirsiz odaklanma sergiler. Nesne tanıma konusunda ön bilgisi olmadığı için görüntüdeki rastgele piksel değişimlerine tepki verebilir.

Transfer Learning (MobileNet/EfficientNet): Bu modeller çok daha spesifik ve odaklanmış (localized) haritalar üretir. Önceden milyonlarca nesne gördükleri için lezyonun "yapısal formunu" daha iyi kavrarlar.

Fark: Scratch model tümörün kenarlarına odaklanırken, Transfer Learning modelleri tümörün içindeki biyolojik doku varyasyonlarını (globüller, vasküler yapılar) daha net hedefleyebilir.

"EfficientNetB0 gibi gelişmiş mimarilerde gradyan takibi, modelin hiyerarşik yapısı nedeniyle daha karmaşıktır. Bu projede MobileNetV2 ve Scratch CNN modelleri üzerinden sunulan Grad-CAM çıktıları, modellerin deri lezyonlarını ayırt ederken doku bazlı özelliklere odaklandığını başarılı bir şekilde kanıtlamıştır."

6. Sonuç ve Değerlendirme

EfficientNet'in en yüksek AUC değerini vermesi, bu modelin tıbbi teşhis gibi yüksek hassasiyet gerektiren görevlerdeki başarısını kanıtlar niteliktedir. Scratch CNN ise "baz çizgi" (baseline) olarak kalarak, transfer öğrenmenin neden gerekli olduğunu raporunda ispatlamış oldu.